# AAL Dokumentacja

## Podobieństwo cząstkowe ciągów

### Zadanie 13

**Wojciech Wolny**
**pod opieką Mgr Inż. Kamila Dei**

**1. Temat**
Dla dwóch ciągów znaków a i b definiujemy podobieństwo jako długość najdłuższego wspólnego prefiksu dla obu ciągów. Np. podobieństwo ciągów "abc" i "abd" wyniosi 2, natomiast podobieństwo ciągów "aaa" oraz "aaab" wynosi 3. Otrzymując na wejściu ciąg znaków S oblicz sumę podobieństw ciągu S do wszystkich jego sufiksów. Przykładowe rozwiązanie:
Wejście:
ababaa
Wyjście: 11 (6+0+3+0+1+1)

**2. Analiza Zadania:**
Głównym problemem w zadaniu jest wyliczenie najdłuższego wspólnego prefiksu dla całego wyrazu oraz jego dowolnego podsłowa zaczynającego się na znaku j-tym. W moim rozwiązaniu stworzyłem tablicę zinicjalizowaną zerami, w której zapisywałem informacje o najdłuższym wspólnym prefiksie dla słowa zaczynającego się na danym indeksie i całego wyrazu. Mając infromację o porzednich wartościach najdłuższego wspólnego prefiksu dla kolejnych słów mogę skrócić czas potrzebny na policzenie tych wartości. W sytuacji, gdy wartość dla pewnego k jest duża mogę przepisać kolejne wartości z początku tablicy, które powtarzają się w pewnym okresie. Gdy dojdę do początku kolejnego okresu zmniejszam o długość okresu poprzednio zapisaną wartość.

**3. Tryby Wykonywania Programu**
1. Podobieństwo cząstkowe ciągów dla gotowego pliku wejściowego:
    - python aal.py -m1 <nazwa pliku>.txt
    - Tryb: m1
    - Parametry:
        - nazwa pliku z rozszerzeniem ".txt"
    - Dane wejściowe:
        - Plik .txt powinien składać się z jednego ciągu znaków w każdej linii
    - Dane wyjściowe:
        - suma podobieństwa cząstkowego ciągów dla każdego ciągu znaków w poprawnie wprowadzonym pliku
2. Podobieństwo cząstkowe ciągów z generowaniem wartości wejściowej:
    - python aal.py -m2 -n<długość generowanego słowa> -d<stosunek "a" w słowie> -a<size of an alphabet>
    - Tryb: m2
    - Parametry:
        - -n -docelowa długość generowanego słowa
        - -d -stosunek ilości "a" w generowanym słowie do jego całej długości
        - -a -wielkość alfabetu w przedziale max(1, min(-a, 52))
    - Dane wyjściowe:
        - Ciąg znaków "a" i innych losowych liter z ASCII o długości -n ze stosunkiem ilości "a" do długości ciągu -d.

3. Test podobieństwa cząstkowego ciągów
    - python aal.py -m3 -n<długość słowa w pierwszym problemie> -k<liczba problemów> -step<krok między długością słowa w kolejnych problemach> -r<liczba instancji problemu>  -a<size of an alphabet>
    - Tryb: m3
    - Parametry:
        - -n  -długość najmniejszego słowa
        - -k  -liczba problemów
        - -step  -wielkość o którą zwiększamy długość słowa w kolejnym problemie
        - -r  -liczba instancji dla każdego problemu
        - -a  -wielkość alfabetu w przedziale max(1, min(-a, 52))
    - Dane wyjściowe:
        - Tabela z wynikami przeprowadzonego testu. W kolumnach odpowiednio podane informacje o długości słowa w pojedyńczym problemie, średnim czasie wykonywania dla -r instancji oraz współczynnikiem zgodności oceny teoretycznej z pomiarem czasu.

4. Test podobieństwa cząstkowego ciągów z porównanie dla dwóch algorytmów. O złożonościach kwadratowej i liniowej.
- python aal.py -m4 -n<długość słowa w pierwszym problemie> -k<liczba problemów>  -step<krok między długością słowa w kolejnych problemach> -r<liczba instancji problemu> -a<size of an alphabet>
- Tryb: m4
- Parametry:
    - -n  -długość najmniejszego słowa
    - -k  -liczba problemów
    - -step  -wielkość o którą zwiększamy długość słowa w kolejnym problemie
    - -r  -liczba instancji dla każdego problemu
    - -a  -wielkość alfabetu w przedziale max(1, min(-a, 52))
- Dane wyjściowe:
    - Dane w formacie "csv" z nagłówkiem. Kolumny są odzielone przecinkiem, a rzędy znakiem nowej lini.
    - Dane posiadją informację o wielkości słowa w problemie, średnim wynikiem pomiaru czasu, współczynnikiem zgodnościoceny teoretycznej i sumie wartości funkcji dla wszystkich jego instancji dla algorytmu o złożoności kwadratowej oraz dla algorytmu o złożoności liniowej.

5. Dodatkowa funkcja pomocnicza do generowania pseudolosowych ciągów S znajduje się w pliku gen.py:
- python gen.py -n<length of generated word> -d<ratio of a's to the word>  -a<size of an alphabet>
- Tryb: Generuj
- Parametry:
    - -n  -docelowa długość generowanego słowa
    - -d  -stosunek ilości "a" w generowanym słowie do jego całej długości
    - -a  -wielkość alfabetu w przedziale max(1, min(-a, 52))
- Dane wyjściowe:
    - Ciąg znaków o długości -n ze stosunkiem ilości "a" do długości ciągu -d.

**4. Metoda rozwiązania**
W celu rozwiązania zadania wykorzystałem tablicę prefikso-prefiksową. Tablica ta podaje wartość najdłuższego wspolnego słowa dla całego wyrazu oraz jego podsłowa zaczynającego się na pozycji j, gdzie j>0(indeksując od 0). Algorytm budujący tę tablice wykorzystuje informacje o budowie wyrazu na podstawie wcześniej policzonych wartości najdłuższych wspólnych prefiksów.
**Zastosowanie algorytmu**:
Algorytm został wykorzystany w celu policzenia sumy najdłuższych prefiksów całego słowa dla kolejnych sufiksów.
**Złożoności:**
Dla każdego ciągu zostaje wytworzona tablica o jego długości. Złożoność pamięciowa algorytmu jest równa O(N). Na złożoność czasową nie wpływa wielkość alfabetu. Algorytm sprawdza znak w wyrazie więcej niż raz tylko w sytuacji, gdy wyraz ten kończy jeden ciąg znaków i zaczyna nastepny z wyłączeniem sytuacji gdy znak "zaczynający" to znak wcześniej przez nas rozważany. Dodatkową oszczędność zyskujemy w sytuacji, gdy pojawiają się pewne serie powtarzalnych okresów, dzięki którym możemy przepisać wartości ze środka okresu. W tych schematach, jeśli dochodzimy do momentu, w którym zaczyna się następny okres. Algorytm, zamiast sprawdzać po kolei ile jeszcze znaków się dalej powtarza, od sumy indeksu znaku zaczynającego poprzedni okres k oraz wartości w tablicy dla k-tej pozycji odejmuje indeks obecnie sprawdzanego znaku j. Wynik ten odpowaiada odjęciu od długości obecnie rozważanego podciągu długości okresu, w którym przepisywaliśmy wartości. Przeprowadzone testy (tabela 1.) potwierdzają, że nie ma znacznych różnic przy zmianie wielkości alfabetu. Algorytm w optymalny sposób wyszukuje sumę podobieństw cząstkowych ciągów. Najgorszy przypadek zakłada sytuację, w której ani razu nie skorzystamy z przypisania, które jest czynnikiem przyspieszającym działanie algorytmu, gdyż pozwala ominąć porównania znaków lub kalkulowanie wartości na podstawie poprzednich wartości tablicy. Takie scenariusze to na przykład ciąg znaków złożony z tych samych liter lub ciąg gdzie, pierwsza litera ciągu występuje tylko na początku. Na przykład dla ciągu "aaaa" algorytm na początku przejdzie przez cały wyraz i policzy sumę "a" w ciągu. Następnie dla każdego kolejnego indeksu będzie wywoływał funkcję slow_scan(), która będzie wyliczała wartość dla danego indeksu. W teście ciąg złożony z tych samych znaków wypadał nieznacznie gorzej, a ciąg złożony z dwóch liter wypdał najlepiej. Tłumaczenie pierwszej sytuacji przedstawiłem wcześniej w tym akapicie. Algorytm działa nieznacznie sprawniej dla alfabetu dwuelementowego, gdyż ma on większe prawdopodobieństwo wystąpienia okresów, które pozwalają na przepisywanie wartości. Dla programu testowego, czyli trybu czwartego przygotowałem dodatkowo rozwiązanie problemu o złożoności kwadratowej. Algorytm ten sprawdza dla każdego ciągu po kolei każdy sufiks porównując go z ciągiem wejściowym. Metoda ta ma złożoność O(N^2) równolegle dla tych samych ciągów zostaje sprawdzany wynik dla optymalnego agorytmu O(N).

| count | 51 |
|---|---|
| mean | 0.86234 |
| min | 0.786145 |
| std | 0.024809 |
| 25.00% | 0.851837 |
| 50.00% | 0.854933 |
| 75.00% | 0.860116 |
| max | 0.951051 |

*Tabela 1. Wyniki testu porównawczego dla różnych wielkości alfabetu od 1 do 51 znaków dla słów o długości 1000 dla 100 prób dla 10 powtórzeń każdego puszczenia w celu wyeliminowania opóźnień związanych z rozpoczęciem programu. Wartość minimalna odpowiada alfabetowi 2-elementowemu, a wartość maksymalna alfabetowi 1-elementowemu.*

**5. Elementy programu**

Prgoram składa się z dwóch plików:

1. aal.py:
   - Opdowiada za przeliczanie 4 trybów pracy. W celu skorzystania z programu na potrzeby interfejsu graficznego można skorzystać z klasy PrefixSum, która posiada wszystkie potrzebne metody do korzystania ze wszystkich trybów pracy. Głównym elementem jest ustawienie odpowiednich atrybutów dla obiektu klasy PrefixSum i wywołanie funkcji run(), która wykonuje żądany tryb. Klasa PrefixSum potrzebuje klasy Generate z pliku gen.py w celu wygenerowania słowa. Następną klasą w pliku aal.py jest klasa ReadTerminal, która posiada metody do odpowiedniego wyodrębnienia informacji z argumentów podanych z terminalu.
2. gen.py:
   - Odpowiada za generowanie pseudolosowego ciągu wejściowego.
   - W celu skorzystania z programu na potrzeby interfejsu graficznego można skorzytsać z klasy Generate, z której następnie można generować słowa o dowolnej długości i o dowolnym stosunku liczby znaków "a" w całym słowie. Klasa ta jest wykorzystywana przez klasę PrefixSum w celu wykonania trybu drugiego oraz trzeciecgo i czwartego, w których wykorzystywana jest do generowania ciągów testowych.

**6. Rezultat**

Program umożliwia dwa typy analizy wyników. Pierwszym jest -m4, który przygotowuje dane w formacie wartości odzielonych przecinkamki. Dane tak wygenerowane pozwalają przeprowadzić dodatkowe analizy złożoności czasowej i porównania poprawności wyników dla dwóch algorytmów. Na rycinie pierwszej widać wyniki takiej analizy przeprowadzonej w notebooku Podobieństwo cząstkowe ciągów.ipynb dla danych wygenerowanych przez wywołanie pytohn aal.py -m4 -n1000 -k30 -step500 -r10 > out.txt. Jak widać na rycinie algorytm o złożonosci liniowej radzi sobie znacznie lepiej.

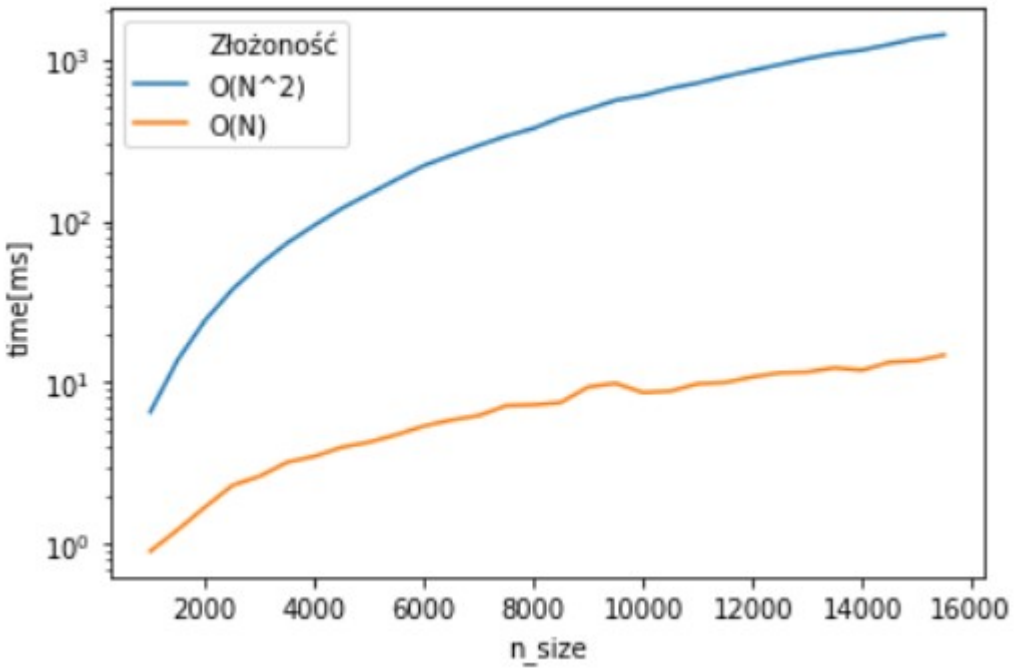


*Ryc. 1 Analiza porównawcza wykonywania programu dla dwóch algorytmów w skali logarytmicznej.*

Drugim trybem analizy jest tryb aal.py -m3 -n1000 -k30 -step500 -r10, gdzie:

- -m3 -tryb wykonywania
- -n1000 długość słowa w pierwszym problemie
- -k30 liczba problemów
- -step500 różnica długości słowa między dwoma kolejnymi problemami
- -r10 liczba instancji problemu

Program zwraca tabelę z analizą złożoności zaprogramowanego algorytmu dla wybranych przez użytkownika parametrów. Program generuje -r instancji (wyrazów) dla odpowiedniego problemu związanego z długością wyrazu równą długości -n minimalnego słowa powiększoną o numer problemu wymnożony przez -step krok (różnicę długości słów między dwoma kolejnymi problemami). Dla każdej instancji program liczy czas na przeliczenie podobieństwa cząstkowego ciągu w milisekundach. W drugiej kolumnie znajduje się średni czas w milisekundach potrzebny na policzenie podobieństwa cząstkowego ciągu o długości dla danego problemu. Ostatnia kolumna prezentuje współczynnik zgodności oceny teoretycznej z pomiaru czasu dla każdego problemu. Jak widać na załączonej rycinie wartości te oscylują w okolicach pożądanej wartości 1.

|###Algorytm z asymptotą O(T(n))###|
|==================================|
|n      |t(n)[ms]       |q(n)      |
|==================================|
|1000   |0.85           |0.9       |
|1500   |1.32           |0.93      |
|2000   |1.76           |0.93      |
|2500   |2.22           |0.94      |
|3000   |2.62           |0.93      |
|3500   |3.07           |0.93      |
|4000   |3.44           |0.91      |
|4500   |3.97           |0.93      |
|5000   |4.42           |0.94      |
|5500   |4.79           |0.92      |
|6000   |5.23           |0.92      |
|6500   |5.9            |0.96      |
|7000   |6.71           |1.01      |
|7500   |7.37           |1.04      |
|8000   |7.71           |1.02      |
|8500   |8.02           |1.0       |
|9000   |8.55           |1.01      |
|9500   |8.79           |0.98      |
|10000  |9.39           |1.0       |
|10500  |9.12           |0.92      |
|11000  |9.21           |0.89      |
|11500  |10.74          |0.99      |
|12000  |11.77          |1.04      |
|12500  |11.63          |0.99      |
|13000  |12.75          |1.04      |
|13500  |12.26          |0.96      |
|14000  |12.67          |0.96      |
|14500  |13.74          |1.0       |
|15000  |13.27          |0.94      |
|15500  |14.16          |0.97      |
|==================================|

*Ryc. 2 Wynik wykonywania programu dla analizy teoretycznej algorytmu wykonanej przez program.*